



Progetto per il corso di MPALN

DISCUSSIONE SUL PAPER: simpler is better: a comparative study of a randomized pivoting algorithms for CUR and interpolative decompositions di Yijun Dong e Per-Gunnar Martinsson

Autore: Giuseppe Di Lella



Dipartimento
di Matematica
Università di Pisa



Table of Contents

1 Presentazione approssimazioni a rango basso

- ▶ **Presentazione approssimazioni a rango basso**
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Definizione di fattorizzazione CUR

1 Presentazione approssimazioni a rango basso

Definizione 1.1 (Fattorizzazione CUR) Si tratta di un'approssimazione di una data matrice $A \in \mathbb{R}^{m \times n}$ espressa come una fattorizzazione che ne usa le righe e le colonne e della forma seguente:

$$A \underset{m \times n}{\approx} \underset{m \times k}{C} \underset{k \times k}{U} \underset{k \times n}{R},$$

dove $C := A(:, J_s)$, $R := A(I_s, :)$ sono sottoinsiemi di righe e di colonne di A linearmente indipendenti, individuate da $I_s \subseteq [n]$ e $J_s \subseteq [n]$ con $|I_s| = |J_s| = k$ (si è usata la notazione $[n] := \{j\text{-uple con } j \leq n\}$). Questi ultimi sono detti scheletri.



Decomposizioni interpolative unilatera

1 Presentazione approssimazioni a rango basso

Definizione 1.2 Dato un sottoinsieme di colonne linearmente indipendenti arbitrario $C := A(:, J_s)$ ($J_s \subset [n]$), l>ID di colonna di rango $|J_s|$ di A rispetto lo scheletro J_s è definita da:

$$\hat{A}_{*, J_s} := CC^\dagger A,$$

dove $CC^\dagger$ è il proiettore sul sottospazio generato dalle colonne di indici in J_s e † denota la pseudoinversa di Moore-Penrose. Analogamente, dato un qualsiasi sottoinsieme di righe linearmente indipendenti $R = A(I_s, :)$ ($I_s \subset [m]$), la ID di riga di rango- $|I_s|$ di A rispetto allo scheletro I_s è data da:

$$\hat{A}_{I_s, *} := AR^\dagger R,$$



Proposte di approssimazioni a rango basso

1 Presentazione approssimazioni a rango basso

Dati due scheletri I_s e J_s con $|I_s| = |J_s|$, sia $S := A(I_s, J_s)$. In questo contesto si possono fornire le seguenti approssimazioni di rango basso, oggetto di studio dell'articolo:

$$\text{ID bilatera:} \quad \hat{A}_{I_s, J_s} := (CS^{-1})S(C^\dagger A)$$

$$\text{Decomposizione CUR:} \quad \tilde{A}_{I_s, J_s} := C(C^\dagger AR^\dagger)R$$

dove nell'aritmetica esatta, poiché $S^{-1}S = I$, la ID a due lati è equivalente alla ID di colonna caratterizzata da C , cioè $\hat{A}_{I_s, J_s} = \hat{A}_{*, J_s}$.



Table of Contents

2 Stabilità delle approssimazioni di rango basso

- ▶ Presentazione approssimazioni a rango basso
- ▶ **Stabilità delle approssimazioni di rango basso**
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Stabilità numerica di CUR e ID bilatera

2 Stabilità delle approssimazioni di rango basso

La costruzione della decomposizione CUR tende ad essere più malcondizionata rispetto a quella della ID a due lati:

- Per scheletri di riga e colonna J_s e I_s opportunamente selezionati, i corrispondenti scheletri S , C e R condividono un decadimento spettrale simile a quello di A , che solitamente è malcondizionata nel contesto.
- Nella decomposizione CUR, sia le basi C , R che la piccola matrice centrale $C^\dagger A R^\dagger$ tendono a soffrire di numeri di condizionamento elevati tanto quanto quelli di A .
- L'unico componente potenzialmente malcondizionato nella ID bilatera è S (ovvero i fattori (CS^{-1}) e $(C^\dagger A)$, nonostante siano espressi tramite S^{-1} e $C^\dagger$ rispettivamente, sono in realtà ben condizionati e possono essere valutati senza inversioni dirette).



Calcolo della CUR numericamente stabile

2 Stabilità delle approssimazioni di rango basso

La costruzione numericamente stabile di una decomposizione CUR $\tilde{A}_{I_s, J_s}$ può essere effettuata tramite la fattorizzazione QR di C e R :

Osservazione: 2.1 siano $Q_C \in \mathbb{R}^{m \times |J_s|}$ e $Q_R \in \mathbb{R}^{n \times |I_s|}$ le matrici della QR le cui colonne formano basi ortonormali rispettivamente per C e $R^\top$ e vale:

$$\tilde{A}_{I_s, J_s} = Q_C \left(Q_C^\top A Q_R \right) Q_R^\top$$



Table of Contents

3 Oblivious embedding di interesse

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ **Oblivious embedding di interesse**
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Definizione di oblivious embedding

3 Oblivious embedding di interesse

Definizione 3.1 Una mappa lineare $S : \mathbb{R}^n \rightarrow \mathbb{R}^\ell$ (matrice aleatoria $S \in \mathbb{R}^{\ell \times n}$) è un (k, ε) -embedding di un sottospazio $L \subseteq \mathbb{R}^n$, di dimensione k , se:

$$(1 - \varepsilon)\|\mathbf{x}\|^2 \leq \|S\mathbf{x}\|^2 \leq (1 + \varepsilon)\|\mathbf{x}\|^2 \quad \forall \mathbf{x} \in L.$$

Definizione 3.2 Un (k, ε, δ) -oblivious subspace embedding è una mappa lineare $S : \mathbb{R}^n \rightarrow \mathbb{R}^\ell$ (matrice aleatoria $S \in \mathbb{R}^{\ell \times n}$) tale che, per un sottospazio $L \subseteq \mathbb{R}^n$ di dimensione k fissato, S è un ε -embedding di L con probabilità almeno $1 - \delta$, ovvero:

$$\mathbb{P}((1 - \varepsilon)\|\mathbf{x}\|^2 \leq \|S\mathbf{x}\|^2 \leq (1 + \varepsilon)\|\mathbf{x}\|^2) \geq 1 - \delta \quad \forall \mathbf{x} \in L.$$



Presentazione degli Oblivious embedding

3 Oblivious embedding di interesse

- **Embedding Gaussiani:** $\Gamma \in \mathbb{R}^{\ell \times m}$ composta da elementi i.i.d. Gaussiani $s_{ij} \sim \mathcal{N}(\mu, 1/\ell)$;
- **Trasformate trigonometriche randomizzate sottocampionate (SRTT):**
 $\Gamma = \sqrt{\frac{m}{\ell}} \Pi_{m \rightarrow \ell} T \Phi \Pi_{m \rightarrow m}$, dove $\Pi_{m \rightarrow \ell} \in \mathbb{R}^{\ell \times m}$ è una selezione uniformemente casuale di ℓ righe su m ; T è una trasformata trigonometrica unitaria $m \times m$ (ad esempio, la trasformata discreta di Hartley per $\mathbb{R}$ e la trasformata discreta di Fourier per $\mathbb{C}$); $\Phi := \text{diag}(\varphi_1, \dots, \varphi_m)$ con variabili casuali di Rademacher i.i.d. $\{\varphi_i\}_{i \in [m]}$ che invertono i segni casualmente; e $\Pi_{m \rightarrow m}$ è una permutazione casuale;
- **Matrici di segno sparse:** $\Gamma = \sqrt{\frac{m}{\zeta}} [s_1, \dots, s_m]$ per un certo $2 \leq \zeta \leq \ell$, con colonne ζ -sparse i.i.d. $\{s_j \in \mathbb{R}^\ell\}_{j \in [m]}$ costruite in modo tale che ogni s_j sia riempita con ζ variabili casuali di Rademacher indipendenti in coordinate uniformemente casuali.



Complessità degli oblivious embedding di interesse

3 Oblivious embedding di interesse

Oblivious embedding	ℓ teorico ottimale	$T_s(\ell, A_k)$
Embedding Gaussiano	$\ell = \Omega(k/\epsilon^2)$	$O(\text{nnz}(A_k)\ell)$
SRTT	$\ell = \Omega(k \log k/\epsilon^2)$	$O(mn \log \ell)$
Matrice di segno sparsa	$\ell = \Omega(k \log k/\epsilon^2), \zeta = \Omega(\log k/\epsilon)$	$O(\text{nnz}(A_k)\zeta)$

Tabella: Nella tabella $A_k \in \mathbb{R}^{m \times n}$ denota una matrice di rango k . La tabella riporta le complessità asintotiche dello sketching, denotate da $T_s(\ell, A_k)$, e i limiti inferiori di ℓ che forniscono garanzia teorica affinché si abbia:

$$(1 - \epsilon)\|A_k x\|_2 \leq \|\Gamma A_k x\|_2 \leq (1 + \epsilon)\|A_k x\|_2, \quad \forall x \in \mathbb{R}^n$$

con probabilità almeno costante. In altre parole, Γ è un (k, ϵ, δ) -oblivious embedding per lo span delle colonne di A_k per δ opportuno.



Table of Contents

4 Stime sull'errore e subottimalità

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità**
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Stima dell'errore ID tramite quello CUR

4 Stime sull'errore e subottimalità

Proposizione 4.1 Comunque costruite C e R a partire da A con una data scelta di scheletri di riga e di colonna, vale:

$$\|A - CC^\dagger A\|_F \leq \|A - CC^\dagger AR^\dagger R\|_F \leq \left(\|A - CC^\dagger A\|_F^2 + \|A - AR^\dagger R\|_F^2 \right)^{\frac{1}{2}}$$

Questo deriva da una semplice decomposizione ortogonale:

$$A - CC^\dagger AR^\dagger R = (I_m - CC^\dagger)A + CC^\dagger(A - AR^\dagger R)$$

dove $(I_m - CC^\dagger)$ e $CC^\dagger$ sono proiettori ortogonali. Pertanto,

$$\begin{aligned} \|A - CC^\dagger AR^\dagger R\|_F^2 &= \|A - CC^\dagger A\|_F^2 + \|CC^\dagger(A - AR^\dagger R)\|_F^2 \\ &\leq \|A - CC^\dagger A\|_F^2 + \|A - AR^\dagger R\|_F^2, \end{aligned}$$



Relazioni dell'errore dello sketch

4 Stime sull'errore e subottimalità

Il risultato precedente assicura che si può controllare l'errore di $\tilde{A}_{I_s, J_s}$ con quello di $\hat{A}_{I_s, J_s}$ e si è perciò si intende proseguire stimando solo il secondo errore. Si vuole ora ottenere una stima dell'errore di $\hat{A}_{I_s, J_s}$ in funzione di quello ottimale secondo la teoria, ovvero, $\|A - A_k\|_F^2$ dove, detto r il rango di A :

$$A = U_A \Sigma_A V_A^\top = [u_{A,1}, \dots, u_{A,r}] \text{diag}(\sigma_{A,1}, \dots, \sigma_{A,r}) [v_{A,1}, \dots, v_{A,r}]^\top$$

$m \times r \quad r \times r \quad r \times n$

$$U_{A,k} := [u_{A,1}, \dots, u_{A,k}] \quad V_{A,k} := [v_{A,1}, \dots, v_{A,k}] \quad \Sigma_{A,k} := \text{diag}(\sigma_{A,1}, \dots, \sigma_{A,k})$$

$$A_k := U_{A,k} \Sigma_{A,k} V_{A,k}^\top$$

Per ottenere quanto voluto, si passa a stimare l'errore dello sketch a partire dalla seguente disuguaglianza presente in letteratura:

$$\|A - AX^\dagger X\|_F^2 \lesssim \ell(\ell - k) \log(\ell - k) \|A - A_k\|_F^2$$



Risultato principale

4 Stime sull'errore e subottimalità

Teorema 1 Dato un approssimatore dello spazio delle righe $X \in \mathbb{R}^{\ell \times n} (\ell \leq r)$ di A che ammette rango per riga pieno, sia $\Pi_n \in \mathbb{R}^{n \times n}$ la permutazione risultante dopo l'applicazione di uno schema di pivoting di colonna appropriato su X che identifichi ℓ pivot di colonna linearmente indipendenti: per la partizione per colonne $(\ell, n - \ell)$ $X\Pi_n = X[\Pi_{n,1}, \Pi_{n,2}] = [X_1, X_2]$, i primi ℓ pivot di colonna $X_1 = X\Pi_{n,1} \in \mathbb{R}^{\ell \times \ell}$ ammettono rango per colonna pieno. Inoltre, la ID di colonna di rango- ℓ $\hat{A}_{*,J_s} = CC^\dagger A$, con scheletri di colonna linearmente indipendenti $C = A\Pi_{n,1}$, soddisfa che:

$$\|A - CC^\dagger A\| \leq \eta \|A - AX^\dagger X\|$$

dove $\eta \leq \sqrt{1 + \|X_1^\dagger X_2\|_2^2}$, e $\|\cdot\|$ rappresenta la norma spettrale o di Frobenius.



Dimostrazione teorema

4 Stime sull'errore e subottimalità

Dimostrazione del Teorema 1. Iniziamo definendo due proiettori obliqui

$$P_X := \Pi_{n,1}(X\Pi_{n,1})^\dagger X, \quad P_C := \Pi_{n,1}(C^\top C)^\dagger C^\top A,$$

$n \times n \qquad \qquad \qquad n \times n$

e osserviamo che, poiché C è composta da colonne linearmente indipendenti, $(C^\top C)^\dagger C^\top A \Pi_{n,1} = I_\ell$, e

$$P_C P_X = \Pi_{n,1}(C^\top C)^\dagger C^\top A \Pi_{n,1}(X\Pi_{n,1})^\dagger X = P_X.$$

Con P_C , possiamo esprimere la ID di colonna come

$$\widehat{A}_{*,J_s} = CC^\dagger A = A \left(\Pi_{n,1}(C^\top C)^\dagger C^\top A \right) = AP_C.$$



Dimostrazione teorema

4 Stime sull'errore e subottimalità

Pertanto, l'errore di approssimazione di basso rango di $\hat{A}_{*,J_s}$ soddisfa

$$\begin{aligned}\|A - CC^\dagger A\| &= \|A(I - P_C)\| \\ &= \|A(I_n - P_C)(I_n - P_X)\| \\ &= \|(I_m - CC^\dagger)A(I_n - P_X)\| \\ &\leq \|I_m - CC^\dagger\|_2 \|A(I_n - P_X)\|,\end{aligned}$$

dove $\|I_m - CC^\dagger\|_2 = 1$, e poiché $XP_X = X_1 X_1^\dagger X = X$ con X_1 a rango pieno,

$$\|A(I_n - P_X)\| = \|A(I_n - X^\dagger X)(I_n - P_X)\| = \|I_n - P_X\|_2 \|A(I_n - X^\dagger X)\|.$$

Come risultato, si ottiene:

$$\|A - CC^\dagger A\| \leq \|I_n - P_X\|_2 \|A(I_n - X^\dagger X)\|,$$



Dimostrazione teorema

4 Stime sull'errore e subottimalità

ed è sufficiente mostrare che $\eta := \|I_n - P_X\|_2 \leq \sqrt{1 + \|X_1^\dagger X_2\|_2^2}$. Infatti,

$$\|I_n - P_X\|_2 = \|\Pi_n^\top \Pi_n - \Pi_n^\top \Pi_{n,1} (X \Pi_{n,1})^\dagger X \Pi_n\|_2 = \left\| I_n - \begin{bmatrix} I_\ell \\ 0 \end{bmatrix} X_1^\dagger [X_1 \quad X_2] \right\|_2 = \left\| \begin{bmatrix} 0 & -X_1^\dagger X_2 \\ 0 & I_{n-\ell} \end{bmatrix} \right\|_2$$

tale che:

$$\eta = \left\| \begin{bmatrix} -X_1^\dagger X_2 \\ I_{n-\ell} \end{bmatrix} \right\|_2 \leq \sqrt{1 + \|X_1^\dagger X_2\|_2^2}.$$

□



Table of Contents

5 Algoritmi pivoting-based

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based**
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Funzionamento dell'algoritmo CPQR deterministico

5 Algoritmi pivoting-based

Sia $X \in \mathbb{R}^{\ell \times n}$, dove $\ell \leq n$, una matrice con rango per riga massimo. Sia $X^{(t)} \in \mathbb{R}^{\ell \times n}$ la matrice risultante dopo il t -esimo passaggio di pivoting e aggiornamento della matrice, considerando $X^{(0)} = X$. Con questa notazione, viene proposto lo svolgimento del generico passo $t + 1$:

- l'algoritmo CPQR cerca nell'intera sottomatrice attiva $X^{(t)}(t + 1 : \ell, t + 1 : n)$ il $(t + 1)$ -esimo pivot di colonna con la norma 2 massima, ovvero, si seleziona:

$$j_{t+1} = \operatorname{argmax}_{t+1 \leq j \leq n} \|X^{(t)}(t + 1 : \ell, j)\|_2.$$

- si applica la permutazione che porta la colonna j_{t+1} ad essere la prima della sottomatrice attiva.
- si applica il riflettore di Householder che rende la prima colonna di $X^{(t)}(t + 1 : \ell, t + 1 : n)$ un multiplo di $e_1 \in \mathbb{R}^{\ell-t}$.



Funzionamento dell'algoritmo CPQR deterministico

5 Algoritmi pivoting-based

Applicando la CPQR a $X \in \mathbb{R}^{\ell \times n}$ si ottiene:

$$X \Pi_n = X \begin{bmatrix} \Pi_{n,1} & \Pi_{n,2} \\ n \times \ell & n \times (n-\ell) \end{bmatrix} = Q_\ell \begin{bmatrix} R_1^{QR} & R_2^{QR} \\ \ell \times \ell & \ell \times (n-\ell) \end{bmatrix},$$

contiene gli ℓ indici di colonna dei pivot che andranno a costituire uno scheletro $J_S \subseteq [n]$.
dove Q_ℓ è una matrice ortogonale; R_1^{QR} è triangolare superiore; e $\Pi_n \in \mathbb{R}^{n \times n}$ è una permutazione delle colonne di X .

Si avrà infine che $\Pi_{n,1}$ contiene gli indici dei pivot selezionati dall'algoritmo che andranno a formare uno scheletro di colonna J_S .



Funzionamento dell'algoritmo LUPP deterministico

5 Algoritmi pivoting-based

Con la stessa notazione del caso CPQR si propone lo svolgimento del passo $t + 1$ di LUPP:

- la LUPP (applicata per colonne) cerca solo nella $(t + 1)$ -esima riga della sottomatrice attiva, $X^{(t)}(t + 1 : \ell, t + 1 : n)$, e seleziona i pivot:

$$j_{t+1} = \operatorname{argmax}_{t+1 \leq j \leq n} |X^{(t)}(t + 1, j)|,$$

- le sottomatrici attive vengono aggiornate tramite i complementi di Schur:

$$\begin{aligned} X^{(t+1)}(t + 2 : \ell, t + 2 : n) &= X^{(t)}(t + 2 : \ell, t + 2 : n) \\ &\quad - X^{(t)}(t + 2 : \ell, t)X^{(t)}(t, t + 2 : n)/X^{(t)}(t, t). \end{aligned}$$



Funzionamento dell'algoritmo LUPP deterministico

5 Algoritmi pivoting-based

Applicando la LUPP per colonne a X si ottiene:

$$X \Pi_n = X \begin{bmatrix} \Pi_{n,1} & \Pi_{n,2} \end{bmatrix} = \underset{n \times \ell}{L_\ell} \underset{\ell \times \ell}{R}^{LU} = \underset{n \times \ell}{L_\ell} \begin{bmatrix} \underset{\ell \times \ell}{R_1^{LU}} & \underset{\ell \times (n-\ell)}{R_2^{LU}} \end{bmatrix},$$

dove L_ℓ è triangolare inferiore; R_1^{LU} è triangolare superiore; $R^{LU}(i, i) = 1$ e $|R^{LU}(i, j)| \leq 1$ per ogni $i \in [\ell]$, $i \leq j \leq n$ in quanto $R^{LU}(i, j) = X^{(i-1)}(i, j)/X^{(i)}(i, i)$ per ogni $i \in [\ell]$, $i + 1 \leq j \leq n$ (eccetto per $R^{LU}(i, j_i) = X^{(i-1)}(i, i)/X^{(i)}(i, i)$); $\Pi_n \in \mathbb{R}^{n \times n}$ è una permutazione di colonna.

Si avrà infine che $\Pi_{n,1}$ contiene gli indici dei pivot selezionati dall'algoritmo che andranno a formare uno scheletro di colonna J_s .



Bound su LUPP e CPQR

5 Algoritmi pivoting-based

A conclusione dell'algoritmo LUPP per colonne, si possono ottenere le colonne restanti (X_2) a partire da quelle selezionate (X_1) come segue:

$$X\Pi = [X_1, X_2] = L_\ell [R_1^{LU}, R_2^{LU}] \in \mathbb{R}^{\ell \times n} \implies X_2 = X_1 \left((R_1^{LU})^{-1} R_2^{LU} \right)$$

Tuttavia, la matrice $(R_1^{LU})^{-1} R_2^{LU}$ può presentare entrate esponenzialmente grandi al crescere delle dimensioni di X . Infatti la stima migliore che è possibile dare su queste entrate è:

$$\max_{1 \leq j \leq n-\ell} \left| \left((R_1^{LU})^{-1} R_2^{LU} \right)_{ij} \right| \leq 2^{\ell-i}, \quad \forall i \in \{1, \dots, \ell\},$$

che vale analogamente nel caso dell'algoritmo CPQR. In particolare, l'uguaglianza è raggiunta, per esempio, quando $R_1^{LU}(i, j) = -1$ per ogni $i \in [\ell - 1], i + 1 \leq j \leq \ell$ e $R_2^{LU}(i, j) = 1$ per ogni $i \in [\ell], j \in [n - \ell]$.



Pseudo-codice generale per algoritmi pivoting-based randomici

5 Algoritmi pivoting-based

Algoritmo di Selezione di scheletri tramite pivoting randomizzato:

Input: $A \in \mathbb{R}^{m \times n}$ di rango r , con $\ell \leq r$.

Output: Indici degli scheletri di colonna e/o di riga, $J_s \subset [n]$ e/o $I_s \subset [m]$, $|J_s| = |I_s| = \ell$.

- Generare un oblivious embedding $\Gamma \in \mathbb{R}^{\ell \times m}$ (tipicamente $\ell \ll \min(m, n)$).
- Costruire lo sketch di riga $X = \Gamma A \in \mathbb{R}^{\ell \times n}$.
- Eseguire LUPP/CPQR per colonne su X , ottenendo J_s , lo scheletro degli ℓ pivot di colonna.
- Eseguire LUPP/CPQR per righe su $C = A(:, J_s)$, ottenendo I_s , lo scheletro degli ℓ pivot di riga.



Miglioramenti di CPQR e LUPP randomici

5 Algoritmi pivoting-based

I metodi di selezione dello scheletro basati su pivoting deterministico soffrono di due svantaggi principali:

- sono insostenibili per problemi su larga scala nelle comuni applicazioni moderne.
- sono vulnerabili a input antagonisti.

L'inserimento di uno sketch randomizzato in questi algoritmi garantisce invece:

- maggiore velocità di esecuzione viene ottenuta eseguendo schemi di pivoting classici su uno sketch $X = \Gamma A \in \mathbb{R}^{\ell \times n}$, per qualche embedding randomizzato Γ , invece che direttamente su A .
- robustezza agli input avversari nella pratica.



Utilizzo del metodo delle potenze

5 Algoritmi pivoting-based

Le iterazioni a potenza, così come le iterazioni nei sottospazi di Krylov e di Krylov a blocchi, possono essere incorporate dopo lo sketching iniziale per gestire meglio i casi in cui A non abbia un buon decadimento dello spettro, oppure, i casi in cui questo risulti piatto. Per esempio, con un oblivious embedding Ω di dimensione $\ell \times n$, un approssimatore dello spazio delle righe con q iterazioni a potenza ($q \geq 1$) è dato da:

$$X = \Omega(A^\top A)^q$$

e richiede $O(T_s(\ell, A) + (2q - 1)\text{nnz}(A)\ell)$ operazioni per essere costruito.

Tuttavia, la semplice applicazione di iterazioni per potenze è numericamente instabile e può portare a grandi errori quando A è malcondizionata e $q > 1$.



Stabilità del metodo delle potenze

5 Algoritmi pivoting-based

Per una costruzione stabile dell'iterazione per potenze, si può eseguire un'ortogonalizzazione ad ogni iterazione:

$$Y^{(1)} = A\Omega^\top$$

$$Y^{(i)} = \text{ortho} \left(A \text{ortho} \left(A^\top Y^{(i-1)} \right) \right) \quad \forall i = 2, \dots, q \text{ (se } q > 1)$$

$$X = \text{ortho} \left(Y^{(q)} \right)^\top A$$

dove $\text{ortho} : \{M \in \mathbb{R}^{d \times \ell} \mid \text{rank}(M) = \ell\} \rightarrow \mathbb{R}^{d \times \ell}$ ($d \geq \ell$) è una mappa che identifica una base ortonormale per M . Ciò ha un costo aggiuntivo complessivo di $O(q(m+n)\ell^2)$.

Inoltre, con un ℓ appropriato che non superi il rango esatto di A , lo sketch di riga $X \in \mathbb{R}^{\ell \times n}$ ha quasi certamente rango per riga pieno.



Table of Contents

6 Ulteriori algoritmi analizzati

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ **Ulteriori algoritmi analizzati**
- ▶ Sperimentazione numerica
- ▶ Sperimentazione in ambito finanziario



Algoritmo DEIM

6 Ulteriori algoritmi analizzati

Un approssimatore dello spazio delle righe di basso rango X può essere successivamente sfruttato per costruire una SVD randomizzata di rango ℓ . Supponendo che ℓ sia scelto correttamente in modo tale che X abbia rango per riga pieno, sia $Q_X \in \mathbb{R}^{n \times \ell}$ una base ortonormale per lo spazio delle righe di X . È stato osservato che la SVD esatta della matrice più piccola $AQ_X \in \mathbb{R}^{m \times \ell}$:

$$\begin{bmatrix} \hat{U}_A, \hat{\Sigma}_A, \tilde{V}_A \end{bmatrix}_{\substack{m \times \ell \\ \ell \times \ell \\ \ell \times \ell}} = \text{svd} \left(\underbrace{AQ_X}_{m \times \ell}, \text{'econ'} \right), \quad \hat{V}_A = Q_X \tilde{V}_A$$

può essere calcolata efficientemente in $O(m\ell^2)$ operazioni e si hanno anche $O(n\ell^2)$ operazioni aggiuntive per costruire $\hat{V}_A$.



Algoritmo DEIM

6 Ulteriori algoritmi analizzati

Questo algoritmo si appoggia al metodo di pivoting LUPP già trattato:

Input: $A \in \mathbb{R}^{m \times n}$ di rango r , con $\ell \leq r$ (tipicamente $\ell \ll \min(m, n)$).

Output: Indici degli scheletri di colonna e/o di riga, $J_s \subset [n]$ e/o $I_s \subset [m]$, $|J_s| = |I_s| = \ell$.

- Generare un oblivious embedding $\Gamma \in \mathbb{R}^{\ell \times m}$ e lo sketch associato $X := \Gamma A \in \mathbb{R}^{\ell \times n}$.
- Costruire la matrice $\widehat{V}_A$ come detto in precedenza.
- Eseguire la LUPP per colonne su $\widehat{V}_A^\top$. Sia J_s l'insieme degli indici degli ℓ pivot di colonna.
- Eseguire la LUPP per righe su $C = A(:, J_s)$. I_s sarà lo scheletro dato dagli ℓ pivot di riga.



Algoritmo Score Leverage

6 Ulteriori algoritmi analizzati

Input: $A \in \mathbb{R}^{m \times n}$, il parametro di rango desiderato k e un parametro di errore ϵ ,

Output: Indici degli scheletri di colonna e/o di riga, $J_s \subset [n]$ e/o $I_s \subset [m]$, $|J_s| = |I_s| = k$.

- Calcolare $v^1, \dots, v^k$ (i primi k vettori singolari destri di A) e gli score di leva statistica (leverage score) normalizzati:

$$\pi_j := \frac{1}{k} \sum_{s=1}^k [v_{A,s}]_j \quad j \in 1, \dots, n$$

- Mantenere la j -esima colonna di A con probabilità $p_j = \min\{1, c\pi_j\}$, per ogni $j \in \{1, \dots, n\}$, dove $c = O(k \log k / \epsilon^2)$.
- Calcolare la matrice C composta dalle colonne scelte di A e lo scheletro relativo J_s .
- Calcolare la matrice R e il relativo scheletro I_s con gli score di leva statistica per righe.



Algoritmo Rangefinder

6 Ulteriori algoritmi analizzati

Per un confronto più generale nella sperimentazione numerica, si propone un ulteriore algoritmo che non ricorre ad approcci *natural basis*. Si tratta dell'algoritmo Rangefinder.

Input: $A \in \mathbb{R}^{m \times n}$, il parametro di rango desiderato k ,

Output: Un'approssimazione di rango k di A (non si costruiscono scheletri).

- Si considera un oblivious embedding $\Gamma \in \mathbb{R}^{k \times m}$ di $A \in \mathbb{R}^{m \times n}$ e si ottiene lo sketch di riga $X = \Gamma A \in \mathbb{R}^{k \times n}$.
- Si estrae una base ortonormale per lo spazio delle righe di A (approssimato da X) tramite fattorizzazione QR *economy-size* della trasposta di X :

$$[Q, \sim] = \text{qr}(X^\top, \text{'econ'}) \quad \text{dove} \quad Q \in \mathbb{R}^{n \times k}$$

- Si considera l'approssimazione data da $A \approx AQQ^\top$.



Table of Contents

7 Sperimentazione numerica

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ **Sperimentazione numerica**
- ▶ Sperimentazione in ambito finanziario



Sperimentazione su matrici SNN

7 Sperimentazione numerica

Definizione 7.1 Le matrici sparse non-negative casuali (SNN) sono matrici sparse casuali sintetiche utilizzate in letteratura per testare algoritmi di selezione dello scheletro. Dati $s_1 \geq \dots \geq s_r > 0$, una matrice SNN casuale $\mathbf{A}$ di dimensioni $m \times n$ assume la forma:

$$\mathbf{A} = \text{SNN}(\{s_i\}_{i=1}^r; m, n) := \sum_{i=1}^r s_i \mathbf{x}_i \mathbf{y}_i^T$$




dove $\mathbf{x}_i \in \mathbb{R}^m, \mathbf{y}_i \in \mathbb{R}^n, i \in [r]$ sono vettori sparsi casuali con elementi non negativi.



Performance degli sketch

7 Sperimentazione numerica

Il calcolo degli sketch, con gli embedding di interesse, su una matrici di tipo SNN, al variare di una dimensione, realizza i seguenti tempi di esecuzione:








Performance degli sketch

7 Sperimentazione numerica

Il calcolo degli sketch, con gli embedding di interesse, su una matrici di correlazione (troncate), al variare di una dimensione, realizza i seguenti tempi di esecuzione:






Benchmark: algoritmi deterministici

7 Sperimentazione numerica

Gli algoritmi di pivoting deterministico LUPP e CPQR, su una matrice di tipo SNN in $\mathbb{R}^{1000 \times 800}$, realizzano i seguenti errori e tempi di esecuzione:






Benchmark: algoritmi deterministici

7 Sperimentazione numerica

Gli algoritmi di pivoting deterministico LUPP e CPQR, su una matrice di tipo SNN in $\mathbb{R}^{2000 \times 1500}$, realizzano i seguenti errori e tempi di esecuzione:






Sperimentazione su matrici SNN (1000 x 800)

7 Sperimentazione numerica

La sperimentazione su una matrice di tipo SNN in $\mathbb{R}^{1000 \times 800}$ ha dato i seguenti risultati:






Sperimentazione su matrici SNN (1000 x 800)

7 Sperimentazione numerica

Si è aggiunto ai precedenti algoritmi anche quello rangefinder:






Sperimentazione su matrici SNN (2000 x 1500)

7 Sperimentazione numerica

La sperimentazione su una matrice di tipo SNN in $\mathbb{R}^{2000 \times 1500}$ ha dato i seguenti risultati:






Sperimentazione su matrici SNN (2000 x 1500)

7 Sperimentazione numerica

Si è aggiunto ai precedenti algoritmi anche quello rangefinder:






Sperimentazione su matrici di correlazione

7 Sperimentazione numerica

Si è scelto una matrice calcolata a partire da 4 mesi di dati sugli asset del S&P100:








Sperimentazione su matrici di correlazione

7 Sperimentazione numerica

Si è aggiunto ai precedenti algoritmi anche quello rangefinder:





Sperimentazione su matrici di correlazione

7 Sperimentazione numerica

Una correzione diagonale produce un leggero miglioramento degli errori:








Table of Contents

8 Sperimentazione in ambito finanziario

- ▶ Presentazione approssimazioni a rango basso
- ▶ Stabilità delle approssimazioni di rango basso
- ▶ Oblivious embedding di interesse
- ▶ Stime sull'errore e subottimalità
- ▶ Algoritmi pivoting-based
- ▶ Ulteriori algoritmi analizzati
- ▶ Sperimentazione numerica
- ▶ **Sperimentazione in ambito finanziario**



Presentazione problema: replica di un indice

8 Sperimentazione in ambito finanziario

Dato un paniere di asset finanziari (per l'attuale contesto si userà l'indice S&P100) si vuole determinare un portafogli, composto da un sottoinsieme degli asset, che replichi in maniera fedele l'andamento del paniere. La costruzione di un portafogli replicante con meno titoli permette di investire ottenendo lo stesso rendimento ma abbassando i costi di transazione. Il problema trova soluzione nell'applicazione degli algoritmi presentati come segue:

- Si costruiscono matrici di correlazione relativi agli asset del paniere su un periodo di tempo desiderato.
- Si applicano gli algoritmi trattati per determinare uno scheletro delle matrici di correlazione. Quest'ultimo suggerisce gli asset da inserire nel portafogli replicante.
- si risolve un problema ai minimi quadrati per trovare la composizione esatta del portafogli replicante (in quali quantità vengono acquistati gli asset).



Dettagli della sperimentazione finanziaria

8 Sperimentazione in ambito finanziario


Per questa sperimentazione si tiene presente che:

- Si suppone di avere accesso ad asset derivati delle azioni dell'S&P100 che garantiscano al portafogli l'esposizione opposta al loro sottostante.
- Si sono utilizzati embedding gaussiani.
- Non si sono riscalate le diagonali delle matrici di correlazione.
- Si sono guardati i comportamenti dei portafogli replicanti anche in periodi successivi a quelli dei campionamenti dati.




Andamento portafogli 15 azioni - 2 mesi di dati

8 Sperimentazione in ambito finanziario



Primo bimestre




Secondo bimestre



Andamento portafogli 15 azioni - 2 mesi di dati

8 Sperimentazione in ambito finanziario



Terzo bimestre

Performance dei
portafogli replicanti in
norma L^1 .

Bimestre 1	Errore L_1
LUPP	1961.3999
LUPP1	3350.1857
CPQR	2479.0352
CPQR1	1352.2784
DEIM	4622.2225
LS	2925.6545


Bimestre 2	Errore L_1
LUPP	4321.1422
LUPP1	2521.7167
CPQR	792.0844
CPQR1	1150.3413
DEIM	751.0881
LS	1358.7329

Bimestre 3	Errore L_1
LUPP	592.6889
LUPP1	2856.6337
CPQR	889.9220
CPQR1	1093.8290
DEIM	3008.6690
LS	1275.8542



Andamento portafogli 15 azioni - 3 mesi di dati

8 Sperimentazione in ambito finanziario




Trimestre 1	Errore L_1
LUPP	2005.0211
LUPP1	454.4686
CPQR	2358.8153
CPQR1	1557.3717
DEIM	676.9855
LS	862.9478

Performance del
portafoglio replicante in
norma L^1 .



Andamento portafogli 15 azioni - 3 mesi di dati

8 Sperimentazione in ambito finanziario




Trimestre 2	Errore L_1
LUPP	2005.0211
LUPP1	454.4686
CPQR	2358.8153
CPQR1	1557.3717
DEIM	676.9855
LS	862.9478

Performance del
portafoglio replicante in
norma L^1 .



Andamento portafogli 15 azioni - 4 mesi di dati

8 Sperimentazione in ambito finanziario




Quadrimestre	Errore L_1
LUPP	2073.6553
LUPP1	3274.8493
CPQR	4193.0023
CPQR1	1329.7475
DEIM	1413.0126
LS	3402.7539

Performance del
portafoglio replicante in
norma L^1 .




Andamento portafogli 30 azioni - 2 mesi di dati

8 Sperimentazione in ambito finanziario



Primo bimestre




Secondo bimestre



Andamento portafogli 30 azioni - 2 mesi di dati

8 Sperimentazione in ambito finanziario



Terzo bimestre

Performance dei
portafogli replicanti in
norma L^1 .

Bimestre 1	Errore L_1
LUPP	1371.3002
LUPP1	1886.3046
CPQR	2829.1684
CPQR1	1240.1283
DEIM	2272.8550
LS	2495.2662


Bimestre 2	Errore L_1
LUPP	1844.7450
LUPP1	706.9783
CPQR	1154.4149
CPQR1	542.5471
DEIM	1125.8361
LS	1212.5758

Bimestre 3	Errore L_1
LUPP	629.3641
LUPP1	744.1758
CPQR	2132.9419
CPQR1	1088.0283
DEIM	1085.5806
LS	1625.4009



Andamento portafogli 30 azioni - 3 mesi di dati

8 Sperimentazione in ambito finanziario




Trimestre 1	Errore L_1
LUPP	785.3473
LUPP1	442.3454
CPQR	655.2055
CPQR1	1410.1786
DEIM	638.8009
LS	962.1008

Performance del
portafoglio replicante in
norma L^1 .



Andamento portafogli 30 azioni - 3 mesi di dati

8 Sperimentazione in ambito finanziario




Trimestre 2	Errore L_1
LUPP	1850.5609
LUPP1	1411.6354
CPQR	725.9167
CPQR1	1301.2091
DEIM	1037.1652
LS	873.8028

Performance del
portafoglio replicante in
norma L^1 .



Andamento portafogli 30 azioni - 4 mesi di dati

8 Sperimentazione in ambito finanziario



Quadrimestre	Errore L_1
LUPP	1048.0397
LUPP1	1696.8609
CPQR	930.0597
CPQR1	1367.1359
DEIM	809.7631
LS	4506.0837

Performance del
portafoglio replicante in
norma L^1 .



Errori medi

8 Sperimentazione in ambito finanziario

Per una migliore comprensione qualitativa dei risultati relativi ai portafogli replicanti a 30 azioni, sono qui riportati gli errori in norma L^1 su periodi di 2, 3 e 4 mesi e su un totale di 25 prove:

Bimestre	Errore Medio L_1 (25 prove)
LUPP	1705.6031
LUPP1	2021.3007
CPQR	2813.4423
CPQR1	2687.9329
DEIM	2700.2107
LS	2964.7414

Trimestre	Errore Medio L_1 (25 prove)
LUPP	1110.2010
LUPP1	980.4484
CPQR	1162.5113
CPQR1	1151.9217
DEIM	960.3144
LS	1195.7362

Quadrimestre	Errore medio L_1 (25 prove)
LUPP	1451.1062
LUPP1	1730.6862
CPQR	1836.8280
CPQR1	1653.1442
DEIM	1602.3783
LS	2405.5265



Conclusioni

8 Sperimentazione in ambito finanziario

Dai risultati complessivi, ottenuti sulla sperimentazione numerica di ambito finanziario, si possono concludere alcune osservazioni:

- Leverage Score sembrerebbe essere in maniera consistente il peggiore degli algoritmi.
- LUPP e LUPP ad un passo di metodo delle potenze, spiccano per avere errori bassi e relativamente consistenti.
- CPQR e CPQR ad un passo di metodo delle potenze, sembrano molto suscettibili ai periodi di forte oscillazione dell'indice.